Campus-DDoS-SDN: un banco de pruebas basado en Python para la detección de ataques DDoS multivector en redes de campus definidas por software

Anna Olenka Calderón Leiva[a], Ricardo Alexander Llanos Lozano[a], Cristhian Emilio Martínez Casas[a,*] and Alessandro Piero Poves Martínez[a]

[a] *Universidad Nacional del Centro del Perú, , Huancayo, , , Peru*

ARTICLE INFO

Keywords:
Redes definidas por software
Aprendizaje automático
Detección de ataques DDoS
Mininet
Clasificación de tráfico de red

ABSTRACT

Campus-DDoS-SDN es un banco de pruebas en Docker que genera y clasifica cuatro ataques DDoS contra el portal de un campus emulado con Mininet y Ryu. Los alumnos siguen navegando durante el ataque y cada flujo se etiqueta por la IP de origen, no por el archivo. Un bosque aleatorio, entrenado sin direcciones IP y probado en el laboratorio de Ciencias Agrarias, obtiene un F1 macro de 1,000. En la sonda del portal, httpflood: la pagina tarda mas; suben los paquetes al portal; icmpflood: suben los paquetes al portal; slowloris: la pagina deja de abrir; synflood: suben los paquetes al portal. En la prueba de Agrarias la clase ICMP reúne 129 flujos, de modo que las cinco clases se informan.

1. Introducción

Las redes definidas por software (SDN) separan el plano de control del plano de datos, concentrando la inteligencia de la red en un controlador lógicamente centralizado [1]. Esta centralización simplifica la gestión de la red, pero también convierte al controlador en un punto único de falla: un ataque de denegación de servicio distribuido (DDoS) que sature al controlador, a los switches, o a un servicio alojado puede degradar o tumbar todo el segmento de red que gobierna. Detectar estos ataques a tiempo, y separarlos de forma confiable de picos de tráfico legítimo, requiere datasets que sean a la vez representativos de despliegues SDN reales y etiquetados con precisión.

La mayoría de los datasets de detección de intrusiones disponibles públicamente, como NSL-KDD [6], CICIDS2017 [4] y CICDDoS2019 [5], no fueron capturados dentro de un entorno SDN: carecen de señales propias de OpenFlow, como la ocupación de la tabla de flujos o la carga del controlador, y sin embargo suelen reutilizarse fuera de ese contexto para entrenar clasificadores orientados a SDN. Trabajos recientes empezaron a cerrar esta brecha generando datasets de DDoS directamente dentro de bancos de pruebas Mininet/Ryu. Kumar y Gupta publicaron dos datasets de un solo vector construidos así: un dataset de inundación TCP-SYN [2] y, más recientemente, un dataset de inundación ICMP [3] en el que el tráfico normal se captura conectando un host de Mininet a una conexión real a internet y navegando sitios web reales (YouTube, Facebook, noticias, etc.), en vez de depender de generadores de tráfico sintético. Este enfoque de tráfico real aumenta el realismo, pero introduce dos limitaciones prácticas para un benchmark reutilizable: el dataset resultante queda atado a un solo vector de ataque, y no es reproducible entre corridas, ya que el contenido y los tiempos capturados dependen de lo que el internet real ofrezca en el momento de la captura.

Este trabajo, Campus-DDoS-SDN, aborda ambas limitaciones dentro de un único banco de pruebas completamente reproducible. Se lanzan cuatro vectores de ataque (inundación TCP-SYN, inundación HTTP, Slowloris e inundación ICMP) desde hosts ya comprometidos contra una misma víctima compartida, un portal web, dentro de una topología Mininet/Ryu que imita un campus universitario: un esquema de switches core/DMZ más un laboratorio emulado por área académica. A diferencia de los datasets previos de un solo vector o de capturas totalmente separadas, los usuarios legítimos siguen navegando el portal durante todo el ataque, de modo que cada captura mezcla flujos benignos y maliciosos contra el mismo objetivo, tal como ocurriría en un incidente DDoS real. Las etiquetas de verdad fundamental se asignan por IP de origen en vez de por archivo de captura, y cada corrida además registra el efecto del ataque sobre la víctima tal como lo percibe un cliente real (código de respuesta HTTP, latencia, conexiones activas), junto con indicadores a nivel de red (paquetes y bytes por segundo, tamaño de la tabla de flujos OpenFlow). El entorno completo, incluyendo los generadores de tráfico, el portal web propio y el pipeline de etiquetado, se empaqueta como una imagen Docker para eliminar cualquier dependencia de una conexión a internet en vivo o de un sistema operativo de host específico. El banco de pruebas incluye dos pipelines de detección complementarios: uno por flujo individual, basado en características CICFlowMeter, y uno por ventana de tiempo, que agrega métricas del portal y telemetría OpenFlow por segundo para permitir la detección temprana del ataque.

Los principales aportes de este trabajo son:

i. Un dataset de DDoS multiclase que cubre cuatro vectores de ataque contra una misma víctima dentro de una topología SDN realista y multisegmento, en vez de un solo tipo de ataque contra una red plana.

cristhianmartinezcasas@gmail.com (C.E.M. Casas)
ORCID(s):

Table 1
Metadata del código.

Nr.	Descripción	Completar en esta columna
C1	Versión actual del código	v1.0
C2	Enlace permanente al repositorio de esta versión	Completar la URL al publicar
C3	Enlace permanente a la Reproducible Capsule	–
C4	Licencia legal del código	MIT
C5	Sistema de control de versiones usado	git
C6	Lenguajes, herramientas y servicios usados	Python, Bash, Mininet, Open vSwitch, Ryu, CICFlowMeter, Docker
C7	Requisitos de compilación, entornos y dependencias	Docker, Ubuntu 24.04; Python 3.9.25 y 3.12.3
C8	Enlace a documentación para desarrolladores	Ver `README.md` del repositorio
C9	Email de soporte	cristhianmartinezcasas@gmail.com

ii. Etiquetado por flujo y por IP de origen que mantiene mezclado el tráfico legítimo y malicioso dentro de la misma captura, más cercano a un escenario de ataque real que las capturas totalmente separadas usadas en trabajos previos.

iii. Métricas de impacto combinadas a nivel de red (estadísticas de flujo y paquetes vía CICFlowMeter) y a nivel de aplicación (estado HTTP, latencia, saturación de conexiones), capturadas automáticamente en cada corrida.

iv. Un entorno Docker de un solo comando, completamente reproducible, que no depende de una conexión a internet en vivo, resolviendo la limitación de reproducibilidad de los datasets SDN basados en tráfico real.

v. Un clasificador de bosque aleatorio, entrenado sin usar la IP, junto con un pipeline preparado para mezclar capturas Wireshark de tráfico benigno de estudiantes (autorizadas) con los ataques solo simulados.

vi. Telemetría del controlador OpenFlow exportada en cada corrida por una aplicación Ryu propia: instala flujos por IP de origen y sondea periódicamente las estadísticas de la tabla de flujos (paquetes, bytes, entradas activas), que el pipeline une con las métricas del portal por ventana de tiempo. Esto aporta las señales SDN específicas que los datasets no-SDN reutilizados no tienen.

vii. Un dataset por ventana de tiempo (una fila por segundo, con contadores del portal y telemetría SDN agregada) y un pipeline de detección temprana evaluado con validación cruzada leave-one-run-out sobre cinco corridas independientes. El bosque aleatorio obtiene F1 macro = 0,999 ± 0,001 y F1 binario = 1,000 ± 0,000 (sin falsos positivos). Una ablación de grupos de características muestra que la telemetría SDN aporta +0,054 de F1 macro sobre usar solo los contadores de red, y es decisiva para separar la inundación ICMP de la TCP-SYN.

2. Planteamiento de la investigación

2.1. Problema

Una precisión alta obtenida con un solo tipo de ataque y capturas separadas no demuestra que el detector pueda reconocer tráfico malicioso cuando los usuarios legítimos siguen usando el mismo servicio. Además, una evaluación que depende de navegar internet en vivo cambia entre corridas. Por ello, el problema abordado es cómo construir una base reproducible que mezcle tráfico benigno y cuatro ataques contra el mismo portal, y que permita probar el modelo en un laboratorio distinto de los usados para entrenarlo.

2.2. Pregunta, objetivo e hipótesis de trabajo

La pregunta es si las estadísticas de flujo, sin direcciones IP, puertos ni tiempo, permiten separar `BENIGN`, `synflood`, `httpflood`, `slowloris` e `icmpflood` en un área académica no vista. El objetivo general es implementar y evaluar ese banco en Docker. Los objetivos específicos son: (i) modelar una topología de campus; (ii) capturar tráfico mixto; (iii) convertir y etiquetar los pcap; (iv) medir el efecto sobre el portal y el contenedor; y (v) evaluar un bosque aleatorio con separación por laboratorio. La hipótesis de trabajo es que las características de tamaño, duración y tasa del flujo permiten lograr un F1 macro mayor a 0,90 en el laboratorio retenido. Esta hipótesis se contrasta primero en casa; la validación con tráfico real de la UNCP queda como fase propuesta y autorizada.

3. Flujo de trabajo

Todo el experimento se lanza con un solo comando sobre la imagen Docker `ataque-sdn`. Dentro del contenedor se levantan, en orden, el controlador Ryu, Open vSwitch y la topología Mininet; luego se ejecuta el escenario pedido y se recogen las salidas. El flujo completo va del campus emulado a los dos datasets etiquetados (por flujo y por ventana de tiempo) y a sus detectores (Fig. 2).

3.1. Topología y población

La topología reproduce un campus reducido: un módem de borde, un switch *core*, una DMZ que aloja el portal web (la víctima, `10.0.0.10`) y un laboratorio por área académica,

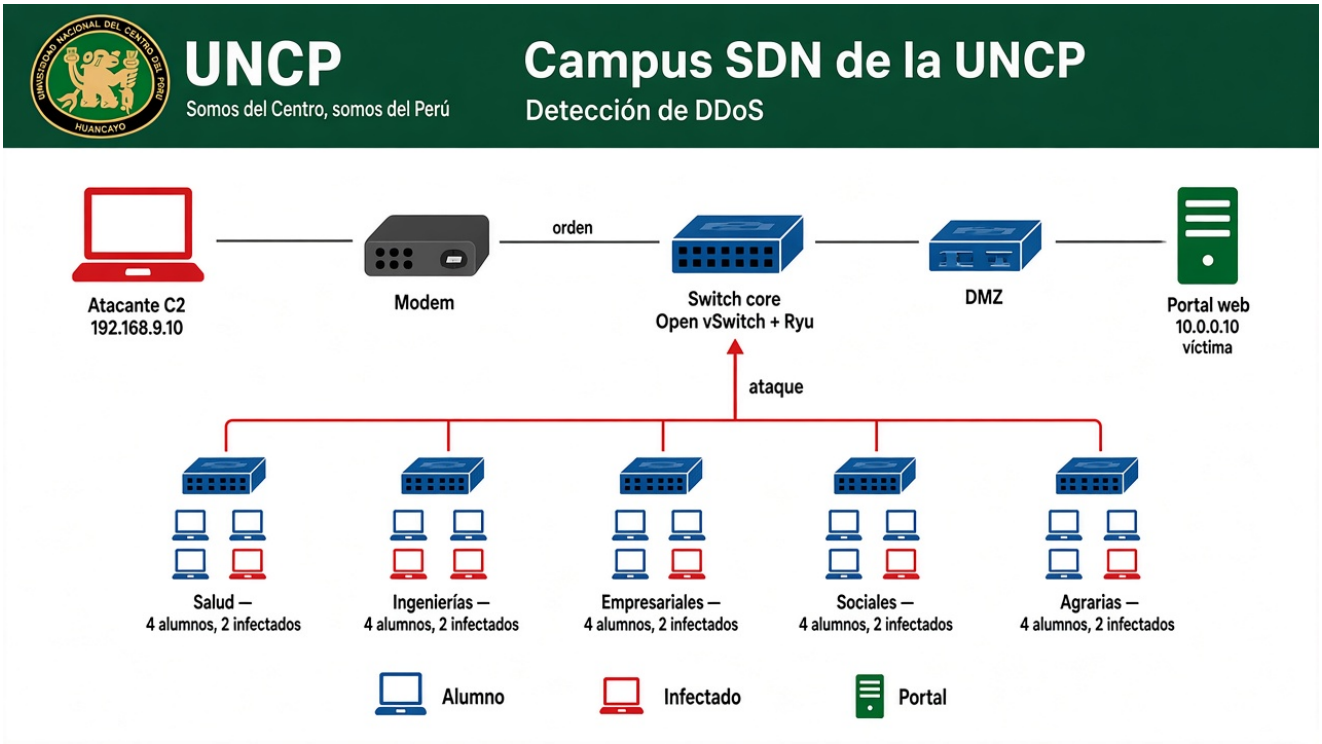


Figure 1: Topología emulada. El C2 queda fuera del campus; las PCs infectadas atacan el portal mientras los alumnos continúan navegando.

conectados por siete switches Open vSwitch gobernados por Ryu. Cada laboratorio tiene cuatro alumnos y dos PC comprometidas (20 alumnos y 10 PC infectadas en total). El centro de mando (C2) queda del lado de internet del módem (`192.168.9.10`); todo el campus vive en `10.0.0.0/8`. Durante un ataque los alumnos siguen pidiendo páginas del portal, y el navegador del operador entra como un cliente benigno más (`http://127.0.0.1:8080/` → `10.9.0.1`). El ataque no sale del contenedor.

3.2. Generación de tráfico mixto

Las PC comprometidas lanzan uno de cuatro vectores: inundación TCP-SYN (`hping3`), inundación HTTP, Slowloris (`slowhttptest`) e inundación ICMP. Los floods sostenidos (SYN e ICMP) corren en un bucle con `timeout` que relanza el generador cada 5 s para que el ritmo no decaiga; el ICMP usa el `ping` del kernel, que sostiene la tasa mejor que el modo `-icmp` de `hping3` sobre Open vSwitch. Como el tráfico legítimo nunca se detiene, cada captura mezcla flujos benignos y maliciosos contra el mismo portal. El banco se orquesta con `scripts/docker/run_scenario.sh`, que levanta un escenario o los cinco.

3.3. Captura y medición

Cada escenario deja, además del `pcap` tomado en la interfaz del portal, tres fuentes sincronizadas por segundo: una sonda del alumno (código HTTP, latencia y paquetes por segundo que percibe el portal), la telemetría del controlador OpenFlow, y el consumo del contenedor (CPU, memoria y red) vía `docker stats`. La telemetría SDN la produce una aplicación Ryu propia (`flow_monitor_13.py`) que, además de reenviar, instala un flujo por cada tripleta (IP origen, IP destino, protocolo) y muestrea periódicamente los contadores de esos flujos en el switch (paquetes, bytes y entradas activas). Los contadores se leen del plano de datos del switch para que reflejen el volumen real incluso bajo un flood sostenido, condición necesaria para que la señal de protocolo (en particular la de ICMP) no se pierda en la telemetría.

3.4. Etiquetado por IP de origen

La verdad fundamental se asigna por emisor, no por archivo de captura. Un flujo es `BENIGN` salvo que su IP de origen sea una PC comprometida y el escenario no sea el `baseline`; en ese caso lleva el nombre del ataque. Así el alumno, el portal y todo el `baseline` quedan `BENIGN` incluso dentro de una captura de ataque. Las IP comprometidas vienen en el JSON que acompaña a cada `pcap`.

3.5. Dos datasets, dos tareas

Del tráfico capturado se derivan dos conjuntos complementarios. *Por flujo* (`pcap_to_csv.py`): el tráfico TCP y UDP pasa por CICFlowMeter, que produce estadísticas bidireccionales; el ICMP, que no entra en ese filtro, lo cierra un agrupador propio a los 10 s (sin ese corte cada PC dejaría un único flujo largísimo y la clase quedaría con muy pocas filas). A cada flujo se le añaden columnas `sdn_*` derivadas de la telemetría OpenFlow, cruzadas por IP de origen. Antes de entrenar se descartan la IP origen, la IP destino, los puertos y la marca de tiempo, para que el modelo aprenda comportamiento y no identidad de la máquina; los valores

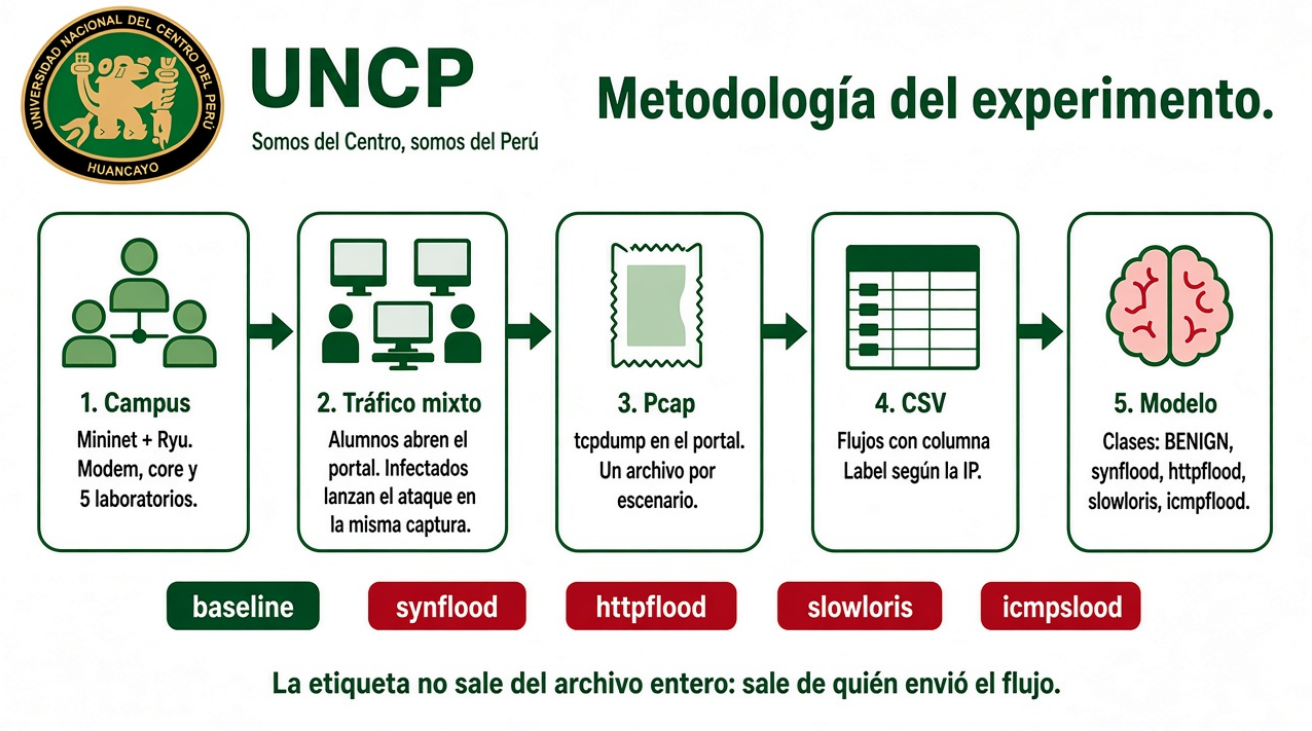


Figure 2: Pipeline del experimento, desde el campus emulado hasta el modelo. La etiqueta se asigna por emisor, no por archivo.

infinitos o vacíos pasan a cero y se quita toda columna constante. El modelo es un bosque de 200 árboles con peso por clase, porque la inundación SYN domina el conjunto. *Por ventana de tiempo* (`build_windows.py`): una fila por segundo que agrega los contadores del portal y la telemetría SDN del intervalo (entropía de las IP de origen, concentración del tráfico, crecimiento de la tabla de flujos y paquetes por protocolo), para la detección *mientras el ataque ocurre*.

3.6. Protocolo de evaluación

Nunca se usa una partición aleatoria, porque ventanas y flujos vecinos están correlacionados. El modelo por flujo (`analisis_completo.py`) se evalúa con un *holdout* de laboratorio: entrenan cuatro áreas académicas (185 127 flujos) y se prueba sobre una no vista, Ciencias Agrarias (45 550 flujos). El detector por ventana se evalúa con validación cruzada *leave-one-run-out* cuando hay dos o más corridas. Para obtener media y desviación el banco ejecuta `run_scenario.sh repeat N`, que repite los cinco escenarios N veces con semillas e intensidades distintas (registradas en el `meta.json` de cada corrida). Los resultados de este artículo salen de cinco corridas de 120 s por escenario.

4. Resultados y panorama de impacto

El dataset de referencia de un solo vector no se puede repetir, porque el tráfico normal sale de internet en vivo [3]. Este banco sí se repite, mezcla alumno y ataque en la misma captura, y ya produce un clasificador. En Ciencias Agrarias, laboratorio que no entró al entrenamiento, el F1 macro es 1,000. La sonda dice qué se siente en la página, no solo qué etiqueta cayó. Con autorización institucional, el mismo pipeline admite tráfico benigno real (Wireshark) sin sacar el ataque del contenedor. La sonda de esa corrida está en la Tabla 2: solo Slowloris deja el portal caído.

Table 2
Sonda del portal (media de cinco corridas de 120 s por escenario).

Escenario	HTTP 200	Fallos	Latencia (ms)	Paquetes/s
baseline	120	0	402	145
synflood	120	0	401	715
httpflood	120	0	644	504
slowloris	1	111	1004	83
icmpflood	120	0	401	319

4.1. Composición del conjunto

Los CSV de las cinco corridas suman 230 692 flujos: 143 133 `synflood`, 46 728 `BENIGN`, 36 595 `httpflood`, 3 598 `slowloris` y 638 `icmpflood`. Esta distribución explica la decisión de ponderar las clases durante el entrenamiento; a diferencia de corridas previas, la clase ICMP reúne ahora suficientes flujos (129 en el laboratorio retenido) para informarse. Además, las capturas de ataque conservan una franja benigna, correspondiente a alumnos que siguen usando el portal.

4.2. Impacto sobre el portal

SYN genera la mayor tasa, 715 paquetes/s, pero la sonda mantiene las 120 respuestas HTTP 200. HTTP flood eleva la latencia media de 402 a 644 ms. Slowloris produce solo

Table 3
Detección (bosque aleatorio). F1 macro 1,000.

Clase	Prec.	Recall	F1	Flujos	En el flujo
BENIGN	1,000	1,000	1,000	8769	se distingue bien
httpflood	1,000	1,000	1,000	7308	se distingue bien
icmpflood	1,000	1,000	1,000	129	se distingue bien
slowloris	1,000	1,000	1,000	708	se distingue bien
synflood	1,000	1,000	1,000	28636	se distingue bien

Table 4
Ablación de grupos de características (bosque aleatorio, por ventana, *leave-one-run-out*).

Grupo de características	F1 macro
Sólo red (contadores del portal)	0,945 ± 0,104
Sólo SDN (telemetría OpenFlow)	0,892 ± 0,115
Todas	0,999 ± 0,001
Aporte del SDN (todas − red)	+0,054

83 paquetes/s, pero ocupa las conexiones disponibles: falla en 111 de 112 intentos. Por tanto, la tasa de paquetes por sí sola no describe el impacto de aplicación.

4.3. Rendimiento del clasificador

El F1 macro en Agrarias es 1,000y el F1 binario `BENIGN` frente a ataque es 1,000. Entre las variables de mayor peso aparecen tanto estadísticas de CICFlowMeter (la media y la variabilidad de la longitud de paquete de ida y el tamaño medio del segmento de ida) como columnas derivadas de la telemetría OpenFlow cruzada por IP de origen (`sdn_avg_pkt_bytes`, `sdn_bytes`, `sdn_pkts`). Esto es coherente con los escenarios –SYN genera segmentos pequeños y repetidos, HTTP intercambia solicitudes y respuestas completas, y Slowloris sostiene conexiones con poco tráfico– y muestra que las señales SDN aportan también a nivel de flujo individual.

4.4. Detección temprana por ventana de tiempo

Sobre el dataset por ventana (una fila por segundo, 2 960 ventanas de cinco corridas independientes) se evaluó el mismo tipo de modelo con validación cruzada *leave-one-run-out*. El bosque aleatorio obtiene F1 macro = 0,999 ± 0,001 y F1 binario = 1,000 ± 0,000, sin falsos positivos en benigno; el recall por clase es 1,000 en `BENIGN`, `httpflood` y `synflood`, 0,998 ± 0,003 en `icmpflood` y 0,996 ± 0,004 en `slowloris`. Una ablación por grupos de características (Tabla 4) separa el aporte de los contadores del portal (“red”) y de la telemetría OpenFlow (“SDN”): la telemetría SDN añade +0,054 de F1 macro sobre usar sólo el portal, y es la que permite distinguir la inundación ICMP de la TCP-SYN, dos ataques que a nivel de contadores del portal se parecen.

4.5. Consumo del banco

La CPU media del contenedor fue 40% en baseline, 36% en SYN, 71% en HTTP, 313% en Slowloris y 35% en ICMP; en Docker, 100% equivale aproximadamente a un núcleo. Slowloris ocupó cerca de tres de los seis núcleos asignados, mientras la memoria máxima observada se mantuvo en torno a 230 MiB (en HTTP flood). Estos valores miden todo el banco (Mininet, OVS, Ryu, portal y generadores), no solo la víctima.

4.6. Discusión

La prueba respalda la hipótesis para las cinco clases: el modelo supera 0,90 de F1 macro sin IP y generaliza hacia un laboratorio retenido. El F1 macro de 0,999 del detector por ventana debe leerse con cautela y no como una afirmación de rendimiento en producción: a resolución de un segundo las ventanas de ataque presentan firmas muy marcadas frente al tráfico benigno, y la evaluación es de laboratorio (*leave-one-run-out* sobre cinco corridas), no un despliegue en línea sobre una red real. El resultado más informativo no es la cifra absoluta sino la ablación: que la telemetría OpenFlow aporte +0,054 de F1 macro, y que sea decisiva para distinguir ICMP de SYN, es la evidencia concreta de que las señales propias de SDN tienen valor discriminante que los datasets no-SDN no ofrecen. La diferencia entre SYN y Slowloris también muestra por qué conviene unir clasificación de flujo con una sonda de servicio: más paquetes no implica necesariamente una página menos disponible.

4.7. Proyectos de investigación en curso que usan el software

El banco se usa en el trabajo de tesis de pregrado de los autores en la Universidad Nacional del Centro del Perú. El protocolo de uso de capturas Wireshark de estudiantes está documentado para el encargado de redes en un documento independiente que acompaña al software.

4.8. Limitaciones y mejoras futuras

El resultado de la tabla sale aún de los alumnos emulados. El dataset híbrido (Wireshark + ataque simulado) queda listo en el código y se actualiza al recibir los pcap autorizados. Cada escenario de esta corrida dura 120 s. ICMP suma 120 flujos en todo el conjunto y 24 en la prueba de Agrarias: el F1 perfecto de esa clase no se informa como resultado consolidado. El clasificador no corre dentro de Ryu; trabaja sobre flujos ya capturados. Trabajo futuro: repetir la prueba con el fondo Wireshark, un escenario mixto de cuatro vectores a la vez, y más muestras ICMP.

4.9. Conclusiones

Campus-DDoS-SDN es un banco de pruebas reproducible, de un solo comando y sin dependencia de internet en vivo, que genera un dataset DDoS multiclase en el que el tráfico benigno y cuatro vectores de ataque conviven en la misma captura contra un único portal. El etiquetado por emisor conserva tráfico benigno dentro de la captura atacada, y la partición por laboratorio ofrece una prueba más exigente que un corte aleatorio. Sobre los flujos ya terminados, un bosque aleatorio entrenado sin IP, puertos ni tiempo alcanza un F1 macro de 1,000 en el laboratorio retenido de Ciencias Agrarias; sobre el dataset por ventana permite la detección temprana con F1 macro de 0,999, donde la telemetría OpenFlow aporta +0,054 y resulta decisiva

Table 5
Requisitos del banco de pruebas.

N.º	Descripción	Herramienta	Versión
1	Emulador de red	Mininet	2.3.0
2	Switch virtual	Open vSwitch	3.3.9
3	Controlador SDN	Ryu	4.34
4	Inundación SYN e ICMP	hping3	3.0.0-alpha-2
5	Ataque de baja tasa	slowhttptest	1.9.0
6	Captura de paquetes	tcpdump	4.99.4
7	pcap a CSV	CICFlowMeter	0.5.0
8	Sistema del contenedor	Ubuntu	24.04

para separar ICMP de SYN. Esto confirma el aporte central del trabajo: las señales propias de SDN, ausentes en los datasets no-SDN reutilizados, tienen valor discriminante medible. Disponibilidad, tasa de paquetes y clasificación describen aspectos distintos del incidente: sólo Slowloris deja el portal caído pese a su baja tasa de paquetes. El resultado, con alumnos emulados, es la base sobre la que se solicita autorización para incorporar tráfico benigno real de la UNCP, sin sacar el ataque del contenedor.

4.10. Publicaciones habilitadas por este software

Aún no hay otra publicación además de este artículo. El software es el que permite esa evaluación.

5. Requisitos de software y hardware

El banco corre en un contenedor Ubuntu 24.04; las versiones de la tabla se leyeron dentro de la imagen `ataque-sdn`. Los modelos se entrenan al correr los scripts de análisis (no son artefactos pre-entrenados): el detector reportado se obtuvo con Python 3.10.12, scikit-learn 0.23.2, pandas 1.3.5, numpy 1.21.5 y matplotlib 3.5.1. Ryu usa Python 3.9.25 en un entorno virtual separado.

Para repetir la corrida basta una computadora de escritorio común, con 8 núcleos y 16 GB de RAM. Docker Desktop puede instalarse en Windows 11 o en Ubuntu. Al contenedor se le asignan 6 CPU y 8 GB, y dentro corre Ubuntu 24.04. Open vSwitch usa el *datapath* de kernel cuando el módulo `openvswitch` está disponible en el host, y cae automáticamente al *datapath* userspace (`netdev`) en caso contrario; la telemetría de flujo refleja correctamente los floods sostenidos en ambos modos.

Agradecimientos

Los autores agradecen a la Universidad Nacional del Centro del Perú.

References

[1] Kreutz, D., Ramos, F.M.V., Veríssimo, P.E., Rothenberg, C.E., Azodolmolky, S., Uhlig, S., 2015. Software-defined networking: A comprehensive survey. Proceedings of the IEEE 103, 14–76. doi:10.1109/JPROC.2014.2371999.

[2] Kumar, S., Gupta, S., 2025. SDN TCP-SYN dataset: A dataset for TCP-SYN flood DDoS attack detection in software-defined networks. Data in Brief 59, 111314. doi:10.1016/j.dib.2025.111314.

[3] Kumar, S., Gupta, S., 2026. ICMP-Flood-SDN: A Python based machine learning application for ICMP flood DDoS attack detection in software defined networks. Software Impacts 27, 100819. doi:10.1016/j.simpa.2026.100819.

[4] Sharafaldin, I., Lashkari, A.H., Ghorbani, A.A., 2018. Toward generating a new intrusion detection dataset and intrusion traffic characterization, in: Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP), pp. 108–116. doi:10.5220/0006639801080116.

[5] Sharafaldin, I., Lashkari, A.H., Hakak, S., Ghorbani, A.A., 2019. Developing realistic distributed denial of service (DDoS) attack dataset and taxonomy, in: Proceedings of the 53rd IEEE International Carnahan Conference on Security Technology (ICCST), pp. 1–8. doi:10.1109/CCST.2019.8888419.

[6] Tavallaee, M., Bagheri, E., Lu, W., Ghorbani, A.A., 2009. A detailed analysis of the KDD CUP 99 data set, in: Proceedings of the 2nd IEEE International Conference on Computational Intelligence for Security and Defense Applications (CISDA).